

各種機械学習モデルによるベンダーエレメント試験の S 波到達点の予測性能比較

樺山 翔哉¹・荻野 俊寛²

¹学生会員 秋田大学 大学院理工学研究科 (〒010-8502 秋田県秋田市手形学園町 1-1)

E-mail: m8022815@s.akita-u.ac.jp

²正会員 秋田大学准教授 大学院理工学研究科 (同上)

E-mail: ogino@gipc.akita-u.ac.jp (Corresponding Author)

受信波形上で S 波到達点の決定がしばしば困難となるベンダーエレメント試験において、機械学習による決定支援を行うための S 波到達点予測モデルの高精度化を目的として、サポートベクター回帰、ガウス過程回帰、ニューラルネットワークの 3 つのアルゴリズムによる機械学習モデルを作成し、予測精度の比較を行った。あらかじめ設定したパラメータの範囲で 7240 通りの受信波形を計算し、その波形における 11 次元の特徴量、真の S 波到達点を学習させ、S 波到達点予測モデルを作成した。学習済みのモデルを用いて実際の実験から得られる受信波形に対して S 波到達点の予測を行い、熟練者が判定した値との誤差を比較することで、3 つの機械学習アルゴリズムの比較を行った。アルゴリズムごと予測に傾向があり、その中でガウス過程回帰の予測が最も熟練者の判定した値に近いことを示した。

Key Words: bender element test, travel time prediction, machine learning, gaussian process regression, neural network, support vector regression

1. はじめに

ベンダーエレメント(以下 BE と記す)法は、BE と呼ばれる 2 枚の圧電素子を貼り合わせたバイモルフ型の振動子を用いて、土供試体を伝播する S 波を測定することにより、手軽に任意の時点・応力点における供試体のせん断弾性係数を評価することができる非破壊試験である。この試験は Shirley and Hampton¹⁾、Dyvik and Madhus²⁾によって導入されて以来、土供試体の S 波速度測定法として一般的になっており、地盤工学会において試験方法の基準化がなされた³⁾。しかしながら、BE 法における受信波は周辺のノイズや反射波、屈折波の他、BE や供試体自身の振動特性など、様々な要因が波の形状に影響することから、S 波到達点の見極めは容易ではない。これまでに S 波到達点の決定方法として、時間領域や周波数領域に基づくさまざまな方法⁴⁻⁷⁾が提案されているが、いずれの方法もすべての土、様々な試験条件において適用可能ではないことから、完全な手法としては受け入れられておらず、決定方法については今なお議論が続いている。Ogino et al.⁸⁾は各種の土に対する実験結果から、同一の土供試体であっても決定方法の違いによって S 波速度に 20%以上の差が生じる場合があることを報告しており、

この問題は深刻である。

BE 試験装置全体をひとつの線形系とみなす概念が 2000 年頃に提案され⁹⁻¹¹⁾、この線形系の概念を用いることで試験装置全体としてのシステムは送信および受信 BE と土供試体の振動特性からなる 3 つのサブシステムの重ね合わせによって表現することができることが示された。任意の入力に対する受信波形は送信波とこれらのサブシステムの伝達関数の積によって計算することができ、これまでに、いくつか報告¹²⁻¹⁶⁾で線形理論に基づいたいくつかの数値計算の結果が報告されており、その妥当性が確かめられている。

S 波到達点の判定法に関しては、実験的、経験的な手法が過去に提案されているものの、前述の通りいずれもすべての土、あらゆる試験条件で適用可能ではないため完全な手法としては受け入れられていない。樺山ら¹⁷⁾は、S 波到達点の決定に機械学習を用いることで、より正確に S 波到達点を予測することができるという仮定のもと、教師あり学習の一つであるサポートベクター回帰を用いて S 波到達点予測モデルを作成し、熟練者が判定した S 波到達点との比較から、サポートベクター回帰モデルにおける S 波到達点予測性能の有効性を確かめた。

本報告では、最終的に機械学習を用いて実験者の S 波

到達点判定の支援を行うという目的のもと、樺山らの結果を踏まえ、新たに機械学習アルゴリズムのガウス過程回帰、ニューラルネットワークを加えて実際の実験から得られた受信波形に対するS波到達点を予測し、熟練者が判定したS波到達点と比較を行なった。また、サポートベクター回帰を含む3つの機械学習モデルの実際の実験データに対する汎化性能を比較した。それぞれのアルゴリズムの特徴は、サポートベクター回帰は古典的であるが、高い汎化性能を有している点、ガウス過程回帰はパラメータの物理的意味が明確である点、ニューラルネットワークは現在最も使用されているアルゴリズムである点にある。

2. 機械学習アルゴリズムの概要

(1) サポートベクター回帰

樺山ら¹⁷⁾がS波到達点予測モデルに使用したサポートベクター回帰¹⁸⁾(以下SVR)を本報告においても使用する。SVRは小規模～中規模のデータセットに適し、高い汎化性能を持つ機械学習のアルゴリズムである。回帰式は式(1)で表される。

$$f(x) = \sum_{n=1}^N (\alpha_n - \alpha_n^*) G(x_n, x) + b \quad (1)$$

ここに、 x は特徴量のベクトル、 N は訓練データの数、 x_n は n 番目の訓練データの特徴ベクトル、 G は x を非線形空間へ写像するカーネル関数、 b は切片を表すベクトルである。カーネル関数にはガウシアンカーネルを用いる。ハイパーパラメータとして、カーネルスケール、ボックス制約、 ε 不感度が最適になるように調整する。

(2) ガウス過程回帰

ガウス過程回帰(以下GPR)では、準備した既知の d 個の訓練データが、ガウス過程と呼ばれる n 次元の多変量正規分布式(2)に従うと仮定し、式(2)からのランダムサンプリングにより確率的に予測値が得られる回帰モデルである。

$$\mathbf{w} = \text{MultiNormal}(\mathbf{0}, \mathbf{\Sigma}) \quad (2)$$

ここに、 \mathbf{w} は n 行の訓練データのS波到達点の正解値からなるベクトル、 $\mathbf{\Sigma}$ は n 行 n 列の分散共分散行列である。 $\mathbf{\Sigma}$ の各要素 $k_{i,j}$ ($i, j = 1, 2, \dots, n$)は対応する訓練データのペアにおける特徴量の相関の程度を表すように定められる。一般に2点間の特徴量の距離が小さいほど訓練データの相関は高いと考えられ、これまでに様々な関数が提案されているが、本報告では後述する最適化の結果、ガウスカーネル(式(3))を用いた。

$$k_{i,j}^G = \theta_0^2 \exp \left[-\frac{1}{2} \sum_{m=1}^d \frac{(x_{im} - x_{jm})^2}{\theta_m^2} \right] \quad (3)$$

ここに、 $x_{i,m}$ 、 $x_{j,m}$ はそれぞれ番号 i 、 j における m 番目の正規化した特徴量、 d は特徴量の次元であり、本報告の場合、後述のように $d=11$ である。 θ_0 は標準偏差であり、 θ_m は m 番目の特徴量についての相関距離を表している。なお、式(3)に線形カーネルを加えることで、1次式や2次式などのトレンド成分を表現することも可能であるが、最適化の結果、本報告では使用していない。したがって、 $\mathbf{\Sigma}$ の各要素 $k_{i,j}$ は式(3)および測定誤差を表すパラメータ θ_{n+1} の和として式(4)で定めた。

$$k_{i,j} = k_{i,j}^G + \theta_{n+1} \delta_{i,j} \quad (4)$$

ここに、 $\delta_{i,j}$ はディラックのデルタである。 $\theta_0 \sim \theta_{n+1}$ はハイパーパラメータと呼ばれ、これらの値を訓練データに基づいて推定する。ハイパーパラメータの推定値が得られたら、式(2)から予測値が得られる。例えば、 $(n+N)$ 個の予測値を計算する場合、式(2)の左辺は $(n+N)$ 行のベクトル、右辺は $(n+N)$ 行 $(n+N)$ 列の行列となり、 $(n+N)$ 次元の多変量正規分布からのランダムサンプリングから予測値が得られる。

(3) ニューラルネットワーク

ガウス過程回帰同様、本報告ではニューラルネットワーク(以下NN)を新たに機械学習アルゴリズムとして追加する。NNは順伝播型NN¹⁹⁾とし、順伝播型NNの構造を図-1に示す。順伝播型NNは、層に並べたノードが隣り合う層との間のみで結合する構造を作り、データが入力から出力まで一方向にしか伝播しないネットワークである。ノードが受け取る入力 u に関して、1層のノードを $i = 1, \dots, N$ 、次層のノードを $j = 1, \dots, T$ で表すと、1層ノードの出力から次層のノードへの入力 u_j は式(5)で表される。

$$u_j = \sum_{i=1}^N w_{ji} x_i + b_j \quad (5)$$

各全結合層において、入力に重み w_{ji} が乗算されてからバイアス b_j が加算される。また、ノードからの出力を z_j




図-1 順伝播型ニューラルネットワーク構造

とすると、出力は式(6)に示す活性化関数 f の出力で表される。

$$z_j = f(u_j) \quad (6)$$

最終層を除く各全結合層の後には活性化関数 f が続き、最終全結合層によって予測値応答が生成される。ハイパーパラメータとして、正則化強度、活性化関数、中間層の層数およびノード数があり、これらは学習結果が最適になるように調整する。

3. 使用するデータの準備

(1) 訓練データおよび検証データ

本報告で使用する GPR, NN は共に教師あり機械学習であり, SVR と同様, 予測モデルの作成のために訓練データとして多くの受信波形を準備する必要がある。教師あり学習では, 説明変数およびそれに対応する目的変数を学習させることで予測モデルを作成する。この時, 十分な予測精度を確保するには大量の学習データが必要となるが, ここで実際の BE 試験から得られる受信波形を使用することは難しい。これは, 一般に BE 試験での受信波の真の S 波到達点は未知であるため, 学習に必要な正解値が得られないことが理由である。本報告で使用する訓練データは, 樫山らが使用したものと同様の方法¹⁷⁾で取得する。取得の方法としては, BE 試験装置が線形系であることを利用して数値計算によって波形を生成し, この人工的な波形を訓練データとして用いる。この手法は Jovićić et al.⁹⁾によって提案され, これまでに著者ら¹⁶⁾を含め, 多くの研究者によってその妥当性が確かめられている¹²⁻¹⁵⁾。Sanchez-Salineró et al.²⁰⁾によって拡張された弾性体の伝達関数を用い, BE の伝達関数としては片持ち板の単純曲げを想定した 1 自由度減衰系のモデルを用いた場合, 計算された波形と実験から得られる波形はおおむね一致することが示されている。この手法によって作成された波形では, 計算時に弾性体と仮定された土供試体の BE 間距離と S 波速度をパラメータとして設定するため, 計算によって出力される受信波形は必然的に真の S 波到達点が既知となる。

線形モデルを用い, BE 試験装置系に送信波として電圧が入力されてから受信波として出力電圧が得られるまでの流れを計算式で示す。送信波および受信波のフーリエ変換をそれぞれ $U(f)$, $V(f)$ とし, 系全体の伝達関数を $H_{TOTAL}(f)$ としたとき, 以下の関係式が成り立つ。

$$V(f) = H_{TOTAL}(f) \cdot U(f) \quad (7)$$

ここに, f は周波数である。また, $H_{TOTAL}(f)$ は送信および受信 BE 系の伝達関数 $H_{BE,T}(f)$, $H_{BE,R}(f)$ と土供試体系の伝達関数 $H_s(f)$ の積として以下のように表される。

$$H_{TOTAL}(f) = H_{BE,R}(f) \cdot H_s(f) \cdot H_{BE,T}(f) \quad (8)$$

一般に, $H_{BE,T}(f)$, $H_{BE,R}(f)$ には BE は片持ち梁を仮定

表-1 パラメータの範囲

送信波の周波数 [kHz]	土の S 波速度 [m/s]	BE 間距離 [mm]	BE 長さ [mm]	土の湿潤密度 [kg/m ³]
1, 2.5, 5, 10, 20, 40, 80	20, 80, 140, 200	10, 37.5, 65, 92.5, 120	3, 6, 9, 12	1000, 1400, 1800, 2200

して一自由度の減衰振動, $H_s(f)$ には供試体を弾性体と仮定して 3 次元弾性体の振動を表す伝達関数の理論式が用いられることから, 本報告でもこれを踏襲した。

$H_{BE,T}(f)$, $H_{BE,R}(f)$, $H_s(f)$ にはパラメータとして BE のサイズおよび BE 間距離, S 波速度などが含まれており, これらのパラメータをあらかじめ設定することでさまざまな土試料, あるいはさまざまな BE や供試体寸法, 任意の送信波 $U(f)$ に対する受信波 $V(f)$ を計算によって容易かつ大量に生成することが可能となる。

受信波形の生成に用いたパラメータの範囲を表-1に示す。表-1に示す範囲で様々に変化, 組み合わせ, 8960 通りの受信波形を生成する。また, 8960 通りのデータの中からパラメータの組み合わせが不適であると考えられるデータを除外した。基準として式(9)に従い, 計算の結果が 1 に満たない値を示した場合は除外する。

$$\frac{L}{\lambda} \leq 1 \quad (9)$$

L は BE 間距離, λ は S 波の波長である。この条件を満たす 7240 通りの受信波形を学習に用いる訓練データとして準備した。計算には土のポアソン比や BE の剛性なども必要となるが, これらのパラメータについては定数とし, 一般的な値を用いた¹⁶⁾。受信波形には最初のピーク点の前に Near-field effect による小さな落ち込みが生じる。この落ち込みは実際の BE 試験の受信波形において典型的に見られる現象であり, Near-field effect の形状は S 波速度だけでなく, P 波速度にも依存する。訓練データの生成において, P 波速度は直接パラメータとしては与えてはいないが, ポアソン比と S 波速度から計算され, 土供試体の伝達関数 $H_s(f)$ に反映されている。実際の BE 試験の受信波は供試体境界での反射や屈折の影響を受けるが, 訓練データとして用いた受信波にはこれらの影響は反映されていない。また, 訓練データの一部は学習には使用せず, ハイパーパラメータ決定のために実施した 5 分割交差検証の検証データとして, モデル性能の評価に用いた。

(2) テストデータ

本報告では, テストデータとして著者らの一人が過去に実施した実験データの一部^{8), 20)}を使用した。実験に使用された試料は豊浦砂, 月面模擬土, 泥炭の 3 種類であり, データの内訳はそれぞれ 61 個, 79 個, 94 個の合計 234 個である。これらの土質特性は対照的であり, 豊浦

表-2 機械学習に用いた特徴量

特徴量	次元数
送・受信 BE の長さ	2
送信波の周波数	1
BE 間の距離	1
土の湿潤密度	1
受信波の正のピーク点の時刻	2
受信波の負のピーク点の時刻	2
受信波のゼロクロス点の時刻	2

砂は粒径が揃った代表的な砂質土試料であり、同一条件で比較すると、3 種類の試料の中では最も大きな S 波速度を示す。月面模擬土は砂質土であるが、細粒分を多く含むため豊浦砂よりも小さな S 波速度を示す²⁰⁾。泥炭は非常に含水比が高く軟弱であることから、S 波速度は著しく小さい。実験から得られる受信波形には実験環境により、トレンドやノイズが含まれているため、前処理としてこれらの除去を行った。トレンドの除去は波形データ全体を直線近似し、その成分を全体から減算することで実施した。また、ノイズの除去はガウス加重移動平均によって実施した。これらの前処理を施した後のデータをテストデータとし、予測に用いた。波形は、試料や実験条件の違いによって大きく形状が異なり、豊浦砂や月面模擬土は泥炭に比べて高周波成分が卓越する。また、実験から得られる波形の立ち上がり付近には微小な振幅がしばしば確認され、これが S 波の到達点を不明瞭にしている。この特徴は数値計算で生成される訓練データには見られないものであることから、テストデータと訓練データは形状的に必ずしも近いものではないことを示している。

4. 特徴量の抽出と予測モデルの作成

(1) 特徴量の抽出

準備した訓練データから、機械学習モデルの学習および予測に用いる特徴量の抽出を行った。学習に用いた特徴量を表-2 に示す。特徴量については、樺山らが使用した特徴量を本報告においても踏襲した¹⁷⁾。特徴量の内訳としては、BE 長さ、送信波の周波数、BE 間の距離、土の湿潤密度、および受信波のピーク点およびゼロクロス点に対応する時刻の合計 11 次元である。ピーク点およびゼロクロス点に対応する時刻は受信波の形状に関する特徴量となる。ピーク点は、受信波形上で正のピーク点から決定する一つのピーク点を基準ピークとして考える。基準ピークの前後に位置する負のピーク点、一つ後の正のピーク点のそれぞれの時刻を特徴量とした。基準ピークは、まず受信波形上において最大値となる振幅の位置を検出し、その位置より前方に最大値の 1/2 以上の値を示す振幅がある場合はその中で時刻が最小である振幅、

該当する振幅がない場合はそのまま最大値を示す振幅とした。ゼロクロス点は、抽出されたピーク点に挟まれた位置にあり、振幅がゼロとなる線と受信波が交差する点とした。したがって、正負のピーク点とゼロクロス点の時刻はそれぞれ交互に現れる。以上の手順により、受信波形における波形の特徴を、合計 6 次元の特徴量として抽出した。

(2) 機械学習モデルの作成

機械学習のアルゴリズムには GPR、NN および SVR の 3 種類を用いた。SVR のハイパーパラメータ s , C , ε の最適化については、樺山らと同様の工程¹⁷⁾で行うものとした。各パラメータ値を所定の範囲で 10 分割し、すべての組み合わせを総当たりするグリッドサーチによって、予測値と真の S 波到達点の二乗平均平方根誤差(RMSE)が最も小さくなるパラメータの組み合わせを探索することで実施した。二乗平均平方根誤差の計算は前述のように 5 分割交差検証を用いた。グリッドサーチにより最適化されたパラメータはカーネルスケール 5.99、ボックス制約 0.22、 ε 不感帯 7.69×10^{-7} であった。GPR では、基底関数、カーネル関数、ノイズ標準偏差、および標準化の有無をベイズ最適化によって調整した。最適化の結果、基底関数は空の行列、カーネル関数は ARD 二乗指数カーネル、ノイズ標準偏差 0.0029、標準化有りであった。NN では、正則化強度を表す λ 、活性化関数、中間層の層数及びノード数を 10 分割グリッドサーチによって調整した。グリッドサーチにおける層数及びノード数の探索範囲は、図-1 に示すように中間層の層数 1-5、ノード数 1-400 とし、これらの条件下で、予測値と真の S 波到達点の二乗平均平方根誤差が最も小さくなるように調整した。最適化の結果、 $\lambda=2.29 \times 10^{-7}$ 、活性化関数は恒等関数、NN の中間層 3 層、ノード数はそれぞれ 28, 14, 7 であった。いずれのモデルでもハイパーパラメータ最適化の際、二乗平均平方根誤差が概ね一定値に収束することを確認した。以上のハイパーパラメータを最適化した 3 つの機械学習モデルを使用して、テストデータでの予測を実施した。

5. モデルの予測精度の確認

作成した機械学習モデルに検証データあるいはテストデータから得られる特徴量を再代入することで、各データに対する S 波到達点の予測値を得ることができる。また、得られた予測値と真の S 波到達点の比較によって、モデルの予測精度の評価を行う。

BE 試験では S 波到達点と伝播距離から S 波速度を算定することが目的であるため、算定される S 波速度の精度の観点からは、予測値と真の S 波到達点の差よりも、




図-2 予測されたS波到達点と真の値の比較




図-3 検証データに対する予測値の誤差の分布(GPR)




図-5 検証データに対する予測値の誤差の分布(SVR)




図-4 検証データに対する予測値の誤差の分布(NN)

真のS波到達点に対する誤差が重要となる。そこで、本報告では予測誤差を(予測値 - 真の値)/真の値として定義する。

(1) 検証データに対する予測結果

各モデルは、グリッドサーチまたはベイズ最適化によってハイパーパラメータを調整することによって作成される。検証データに対する予測は、ハイパーパラメータ最適化の際に、二乗平均平方根誤差を計算するために逐次実施される。各機械学習モデルの予測値と真のS波到

達点の比較を図-2に示す。一部誤差が確認できるが、すべてのモデルにおいて真の到達点に対する予測誤差25%を表す破線の内側にプロットがおおむね収まった。また、傾き1、切片0の直線付近にほとんどのプロットが位置することから、数値計算から得られた受信波に対して精度良く予測が行えたことがわかる。

図-3～図-5は各モデルにおける予測誤差の分布を示している。予測誤差の分母が真の値であるため、到達点の時刻が小さいほど大きい誤差となる傾向を示す。誤差は、SVRでは最大でも10%付近で止まっているが、GPRおよびNNでは最大で100%近くを示す誤差を確認することができる。3つのモデルとも負の誤差に比べて正の誤差が優位であることが確認できるが、GPRではそれがより顕著であり、真の値よりも予測値が過大になる割合が高い傾向を示している。この傾向における要因としては、特徴量の大きさがその一つとして考えられる。また、ヒストグラムから、SVRではデータの全体の95%が約-2%～4%の区間に収まっているのに対して、GPRでは全体の95%が約-10%～50%の区間、NNでは全体の95%が約-20%～25%の区間に収まっており、SVRと比較するとGPRとNNはどちらも誤差の範囲が広く、誤差は大きな値となった。

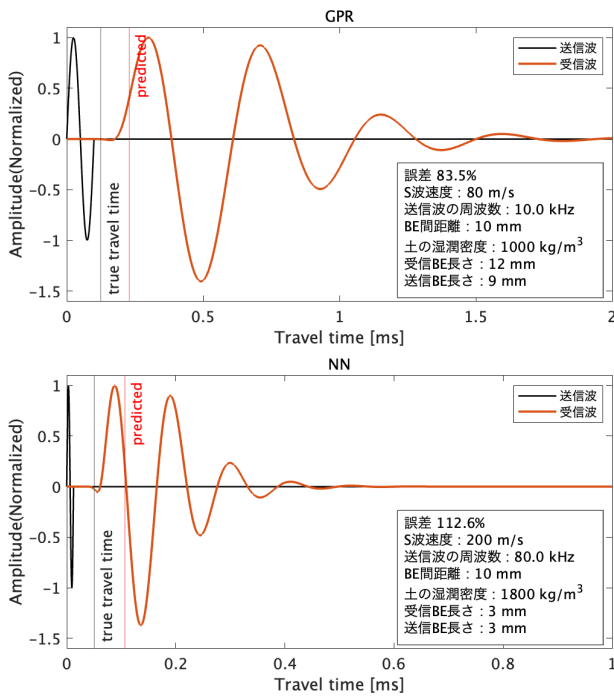


図-6 波形上での真の到達点と予測値の比較

図-6は、GPRおよびNNにおいて予測誤差が最大となったデータについて、実際の送・受信波形上で真の到達点と予測値を比較している。2つのモデルに共通してBE間距離が最小の10mmを取る時に予測誤差が大きくなっている。SVRに関しても同様のBE間距離10mmで誤差が大きくなることから、BE間距離が著しく小さい場合、大きな予測誤差が発生しやすい傾向にあると考えられる。また、予測誤差に及ぼす送信波の影響を確認するため、各モデル誤差が97.5および2.5パーセンタイルの外側にあるデータについて積み上げヒストグラムを図-7に示す。

周波数が高い値を取るケースでは比較的誤差が大きくなることが確認できるため、送信波が高周波数であるほど予測値と真の到達点との乖離が大きくなる傾向があることがわかる。

3つの機械学習モデルの検証データに対する予測では、3つの機械学習モデルのうち、GPR、NNで予測誤差が大きな値となる一方でSVRでは比較的小さい誤差で抑えられていることがわかった。また、BE間距離および送信波の周波数に関する同一の誤差要因を確認した。

(2) テストデータに対する予測結果

本項では、テストデータを用いて予測を行い、実験から得られた波形に対する3つの機械学習モデルの予測精度を検証する。ただし、あらかじめ設定したパラメータから計算によって生成している訓練データや検証データの波形と異なり、実験から得られる受信波形では真のS波到達点未知である。そのため、本報告においては熟練者によるS波到達点の判定値を真のS波到達点の代用として使用する樺山らの案¹⁷⁾を踏襲し、予測値との比較を行った。なお、この熟練者は著者らの一人であり、BE試験について豊富な経験を持つ。また、この熟練者による判定値は本報告よりもはるか以前に得られたものであり、修正することなく本報告のテストデータとして使用している。そのため、テストデータは学習モデルによる予測値の影響を一切受けていない。熟練者による判定値と予測値との比較を図-8に示す。

図-8からわかるように、3つの機械学習アルゴリズムとも各試料に対して大きな外れ値は検出されず、プロットが傾き1の直線付近に集まっていることから、3つのモデルの予測値はおおむね熟練者の判定値と近い値を示すことがわかる。検証データ同様、テストデータに対す

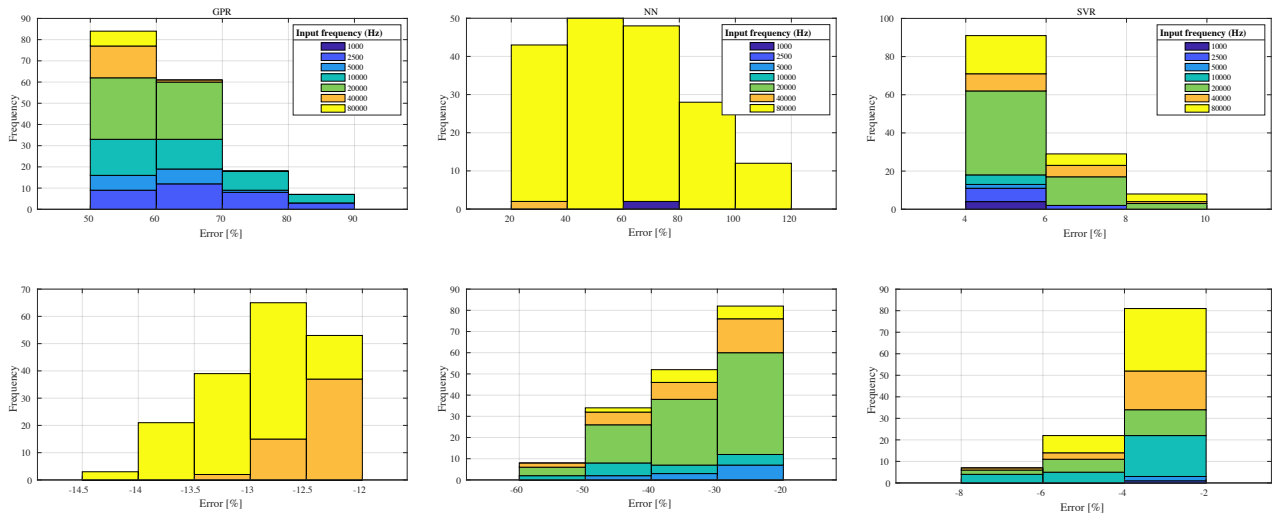


図-7 各モデルの97.5パーセンタイル以上(上)および2.5パーセンタイル以下(下)の誤差の分布




図-8 熟練者による判定値と予測値の比較

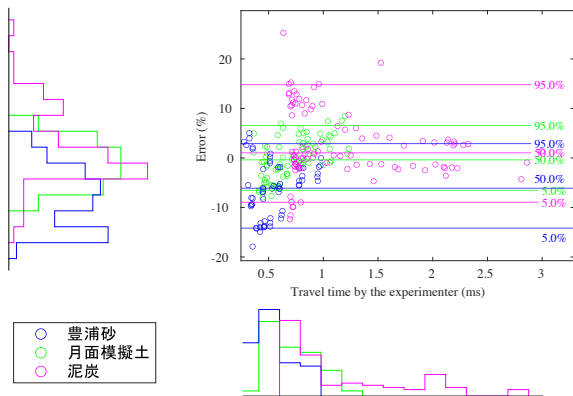


図-9 実験データに対する予測値の誤差の分布 (GPR)

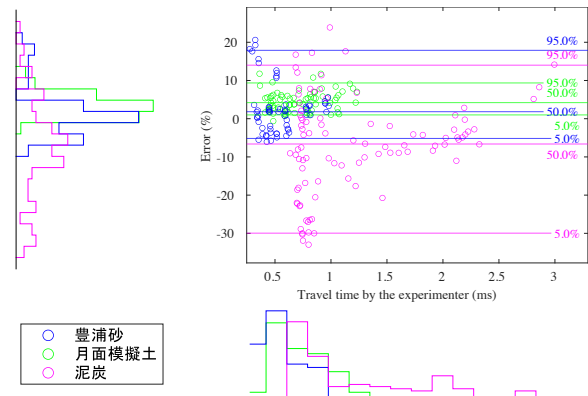


図-11 実験データに対する予測値の誤差の分布 (SVR)




図-10 実験データに対する予測値の誤差の分布 (NN)

る予測誤差の分布を図-9～図-11に示す。試料ごとに色分けされた水平線はそれぞれ、5, 50, 95パーセンタイル点を表している。ヒストグラムから、GPRでは月面模擬土および泥炭では50パーセンタイル点がほとんど0付近にあり、比較的正負で偏りなく誤差が分布する傾向があるのに対して、豊浦砂では50パーセンタイル点は負の領域にあり誤差が負の領域に強く分布することから、GPRにおいて豊浦砂試料ではS波到達点が熟練者の判定値よりも小さく評価される傾向があることがわかる。一

表-3 二乗平均平方根誤差(RMSE)

	GPR	NN	SVR
豊浦砂	4.01×10^5	4.19×10^5	2.99×10^5
月面模擬土	3.01×10^5	7.44×10^5	4.16×10^5
泥炭	7.03×10^5	10.7×10^5	14.1×10^5
全体	5.21×10^5	8.30×10^5	9.36×10^5

方で、NNおよびSVRは類似した誤差の分布を示し、豊浦砂、月面模擬土の分布において50パーセンタイル点が正の領域に、泥炭では負の領域に分布している。この結果から、NNおよびSVRでは砂質土試料の場合熟練者の判定値よりも大きくS波到達点が予測され、泥炭試料では小さく予測される傾向があることがわかる。

全体として、プロットはほとんどが誤差 $\pm 25\%$ 以内に収まっているが、検証データに対する予測と同様にS波到達点が小さくなるほど予測誤差の絶対値が大きくなる傾向が確認できる。特にGPR, NNにおいて、検証データに対するS波到達点の予測結果ではSVRの結果と比較して非常に大きい誤差の値を示したが、テストデータに対する予測では同程度の誤差値を示す結果となった。

(3) 使用した機械学習アルゴリズムの比較

各試料およびモデルごとに算出した二乗平均平方根誤

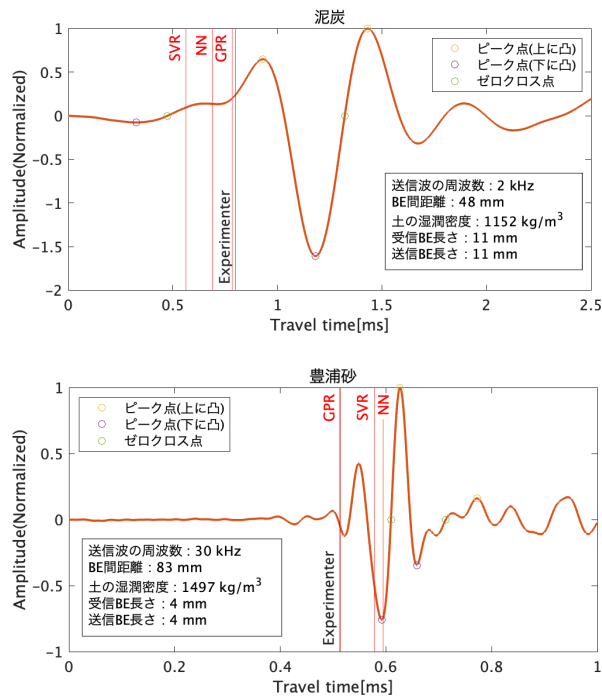


図-12 NN, SVRにおいて予測誤差が大きくなった波形

差(RMSE)を表-3に示す。3つのモデルにおける予測結果では、すべてのモデルに共通して泥炭のRMSEが最も高い値を示していることから、砂質土との土質特性の違いが予測精度に影響を与えていると考えられる。全体としての予測精度は二乗平均平方根誤差が 5.21×10^5 を示したGPRが最も高いことがわかる。他の2つのモデルと比べて泥炭に対する予測の誤差を抑えられたことが予測誤差の差に大きく影響したと考えられる。

GPRと比べてRMSEが大きい値を示したNN, SVRで大きな予測誤差を示したデータの波形を図-12に示す。同波形は図-8において赤で強調しているプロットに対応している。泥炭において予測誤差が大きくなった波形を見ると、波形の立ち上がり付近が小さく波打っており、最初の負のピーク点と正のピーク点の間に小さな下に凸のピークが確認される。このピーク点の振幅は正の値をとるため、4.(1)で述べた本報告で踏襲している特徴量抽出方法では正負どちらのピーク点とも判定されない。泥炭において予測値と熟練者による判定値の乖離が大きくなる場合ではこのケースが多い。また、NN, SVRは、5.(2)で述べたように泥炭においては予測値が熟練者の判定値より小さく予測される傾向があるため、このことも誤差に影響を与え、GPRの予測値に比べて前方にS波到達点が位置したと考えられる。次に、豊浦砂において予測誤差が大きくなった波形を見ると、最大ピークが基準ピークとなっているが、基準ピークの前方にも比較的大きな振幅が確認できる。熟練者の判定値の位置から、熟練者はこの前方の振幅を基準としてS波到達点を決定し

ていることがわかる。豊浦砂で予測値と熟練者による判定値の乖離が大きくなる場合は、以上のように基準とするピークの違いが誤差の原因になるケースが多いことが確認できた。5.(2)で述べたように、GPRでは豊浦砂の予測誤差が負の領域に分布する、つまりS波到達点が小さく予測される傾向があることにより、豊浦砂では予測値と熟練者の判定値の乖離が小さくなったと考えられる。

実際の実験では最初のピークが曖昧な受信波形がしばしば得られる。このようなケースでは、BE法に精通する研究者らでさえ、S波到達点の判定に大きな開きが生じることが指摘されている²⁾。GPRではモデルの予測傾向から、NN, SVRに比べてこの影響が小さかったことが他2つのモデルとの予測誤差に差が生じた要因になったと考えられる。以上から、3つのモデルの比較ではGPRの予測が熟練者の判定値と最も近くなることを示した。

6. 結論

受信波形上でしばしば困難となるS波到達点の決定に対して機械学習による決定支援を目的に、数値計算から生成する受信波形を用いて3種類の機械学習アルゴリズムによるS波到達点予測モデルを学習させ、予測精度の比較を行った。

まず、あらかじめ設定したパラメータの範囲で8960通りの受信波形を計算し、パラメータの組み合わせから条件として非現実的なデータを除外することで7240通りの受信波形を得て訓練データとした。試験条件および送・受信波形の形状に関する11次元の特徴量を抽出し、真のS波到達点とともに機械学習モデルに学習させた。ハイパーパラメータの最適化はグリッドサーチおよびベイズ最適化で行なった。SVR学習済みモデルは数値計算によって得られた受信波形に対して、高い精度でS波到達点の予測を行うことができた。GPR, NNに関しても、おおむね正常に予測を行うことができたが、到達点の時刻が小さい位置において、SVRと比較すると誤差は大きい値を示した。

続いて、実際の実験から得られる受信波形に対してS波到達点の予測を行った。対象とした試料は豊浦砂、月面模擬土、泥炭の3種類とし、その実験データを使用してS波到達点の予測を行った。3つの機械学習アルゴリズムに対して、予測値と熟練者が判定したS波到達点を比較した結果、3つの機械学習アルゴリズムとも各試料に対して大きな外れ値は検出されず、予測値はおおむね熟練者の判定値と近い値を示した。その中で、NNおよびSVRでは、砂質土試料に対する予測誤差が正の領域に強く分布し、泥炭試料では負の領域に強く分布する傾向を示し、一方のGPRでは、豊浦砂に対する予測誤差

が負の領域に強く分布し、月面模擬土および泥炭はおおむね正負均等に分布する傾向を示した。結果として3つのモデルの中では GPR の RMSE が最小であり、最も熟練者の判定値と近い予測結果を示したことが確認できた。

テストデータに対する予想値の比較として本報告では熟練者の判定値を暫定的に正解値として用いたが、熟練者の判定値と作成したモデルによる予測値のどちらがより真の S 波到達点に近いのかを判断することは難しく、GPR が最も S 波到達点予測に優れたモデルであることはあくまで正解値を熟練者の判定値としているケースのみであるといえる。しかし、実際の実験に近い受信波形を再現し、それを訓練データとして使用してモデルの改善を行うことで予測値をより真の S 波到達点に近づけることができる。本報告での結果を受けての今後の検討課題として、モデルのさらなる精度向上に向けた改善および本報告における結果の信憑性を向上させるため、実際の実験で得られるような複雑な受信波形を数値計算によって再現可能にし、これを訓練データとして使用する必要がある。

謝辞：本研究は JSPS 科研費 22K04304 の助成を受けて実施された。ここに記して謝意を表す。

REFERENCES

- Shirley, D.J. and Hampton, L.D.: Shear-wave measurements in laboratory sediments, *J. Acoust. Soc. Am.*, Vol. 63, No. 2, pp.607–613, 1978.
- Dyvik, R. and Madshus, C.: Lab measurements of G_{max} using bender elements, *Advances in the Art of Testing Soils under Cyclic Conditions*, ASCE, pp.186–196, 1985.
- 地盤工学会編：地盤材料試験の方法と解説 [第一回改訂版] – 二分冊の2 – , pp. 832–880, 2020.
- Greening, P.D. and Nash, D.F.: Frequency domain determination of G_0 using bender elements, *ASTM Geotech. Test. J.*, Vol. 27, No. 3, pp.288–294, 2004.
- Viana Da Fonseca, A., Ferreira, C. and Fahey, M.: A framework interpreting bender element tests, combining time-domain and frequency-domain methods, *ASTM Geotech. Test. J.*, Vol. 32, No. 2, pp.1–17, 2009.
- Bonal, J., Donohue, S. and McNally, C.: Wavelet analysis of bender element signals, *Géotechnique*, Vol. 62, No. 3, pp.243–252, 2012.
- Kawaguchi, T., Ogino, T., Yamashita, S. and Kawajiri, S.: Identification method of travel time based on the time domain technique in bender element test for sandy and clayey soils, *Soils Found.*, Vol. 56, No. 5, pp.937–946, 2016.
- Ogino, T., Kawaguchi, T., Yamashita, S. and Kawajiri, S.: Measurement deviations for shear wave velocity of bender element test using time domain, cross-correlation, and frequency domain approaches. *Soils Found.*, Vol. 55, No. 2, pp. 329–342, 2015.
- Jovičić, V., Coop, M. and Simić, M.: Objective criteria for determining G_{max} from bender element tests, *Géotechnique*, Vol. 46, No. 2, pp.357–362, 1996.
- Santamarina, J. and Fam, M.: Interpretation of bender element tests (discussion), *Géotechnique*, Vol. 47, No. 4, pp.873–877, 1997.
- Blewett, J., Blewett, I. and Woodward, P.: Phase and amplitude responses associated with the measurement of shear-wave velocity in sand by bender elements, *Can. Geotech. J.*, Vol. 37, No. 6, pp.1348–1357, 2000.
- Wang, Y., Lo, K., Yan, W. and Dong, X.: Measurement biases in the bender element test, *J. Geotech. Geoenviron. Eng.*, Vol. 133, No. 5, pp. 564–574, 2007.
- Styler, M.A. and Howie, J.A.: Combined time and frequency domain approach to the interpretation of bender-element tests on sand, *ASTM Geotech. Test. J.*, Vol. 36, No. 5, pp.649–659, 2013.
- Alvarado, G. and Coop, M.: On the performance of bender elements in triaxial tests, *Géotechnique*, Vol. 62, No. 1, pp.1–17, 2012.
- Camacho-Tauta, J., Ali, H., Cascante, G. and Vianna Da Fonseca, A.: Experimental and numerical observations of the frequency-domain method in bender-element testing, *J. Geotech. Geoenviron. Eng.*, Vol. 143, No. 2, 04016096, 2017.
- Ogino, T.: Travel time observation using numerical simulation of bender element testing in time and frequency domain, *Soils Found.*, Vol. 59, No. 3, pp.657–670, 2019.
- 縦山翔哉, 荻野俊寛：機械学習を用いたベンダーエレメント試験の受信波形における S 波到達点の予測, *AI・データサイエンス論文集*, Vol. 3, No. J2, pp. 76-84, 2022.
- Vapnik, V.: The nature of statistical learning theory, Springer science & business media, 1999.
- 若林憲人, 生田目崇：Deep Learning を用いたコンテンツマーケティングの評価に関する研究, 経営情報学会 全国研究発表大会要旨集, 2015f 巻 J1-3, 2015.
- Sanchez-Salinerio, I., Roesset, J., Stokoe, K.: Analytical studies of body wave propagation and attenuation. Report GR 86–15, 1986.
- Ogino, T., Kobayashi, T., Takahashi, T. and Kanamori, H.: Velocity profiles in the shallow lunar subsurface deduced from laboratory measurements with simulants, *J. Aerosp. Eng.*, Vol. 29, No. 5, 04016039, 2016.
- Yamashita, S., Kawaguchi, T., Nakata, Y., Mikami, T., Fujiiwara, T., & Shibuya, S.: Interpretation of international parallel test on the measurement of G_{max} using bender elements. *Soils Found.*, Vol. 49, No. 4, pp. 631–650, 2009.

(Received June 30, 2023)

(Accepted August 31, 2023)

Comparison of prediction performance for S-wave arrival point in bender element test using various machine learning models

Shoya MOMIYAMA and Toshihiro OGINO

In Bender Element tests, determining the arrival time of the S-wave is often challenging from received waveforms. To improve the accuracy of S-wave arrival time prediction using machine learning as decision support for experimenters, we created three machine learning models based on support vector regression, Gaussian process regression, and neural network. We compared their prediction accuracies. We obtained 7240 artificial received waveforms with true S-wave arrival times from the linear system theory and trained the models using 11-dimensional features reflected from waveforms and test condition. The prediction performance of three models were compared using the errors between predicted arrival times and the values determined by an expert. The comparison revealed characteristics of each model in prediction and that Gaussian process regression model demonstrated the closest approximation to the values determined by the expert.